08MIAR-Aprendizaje por refuerzo

Sesión 4 – Algoritmos base: Policy Gradient

Universidad Internacional de Valencia

De:
Planeta Formación y Universidades

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

¿Dónde estamos?

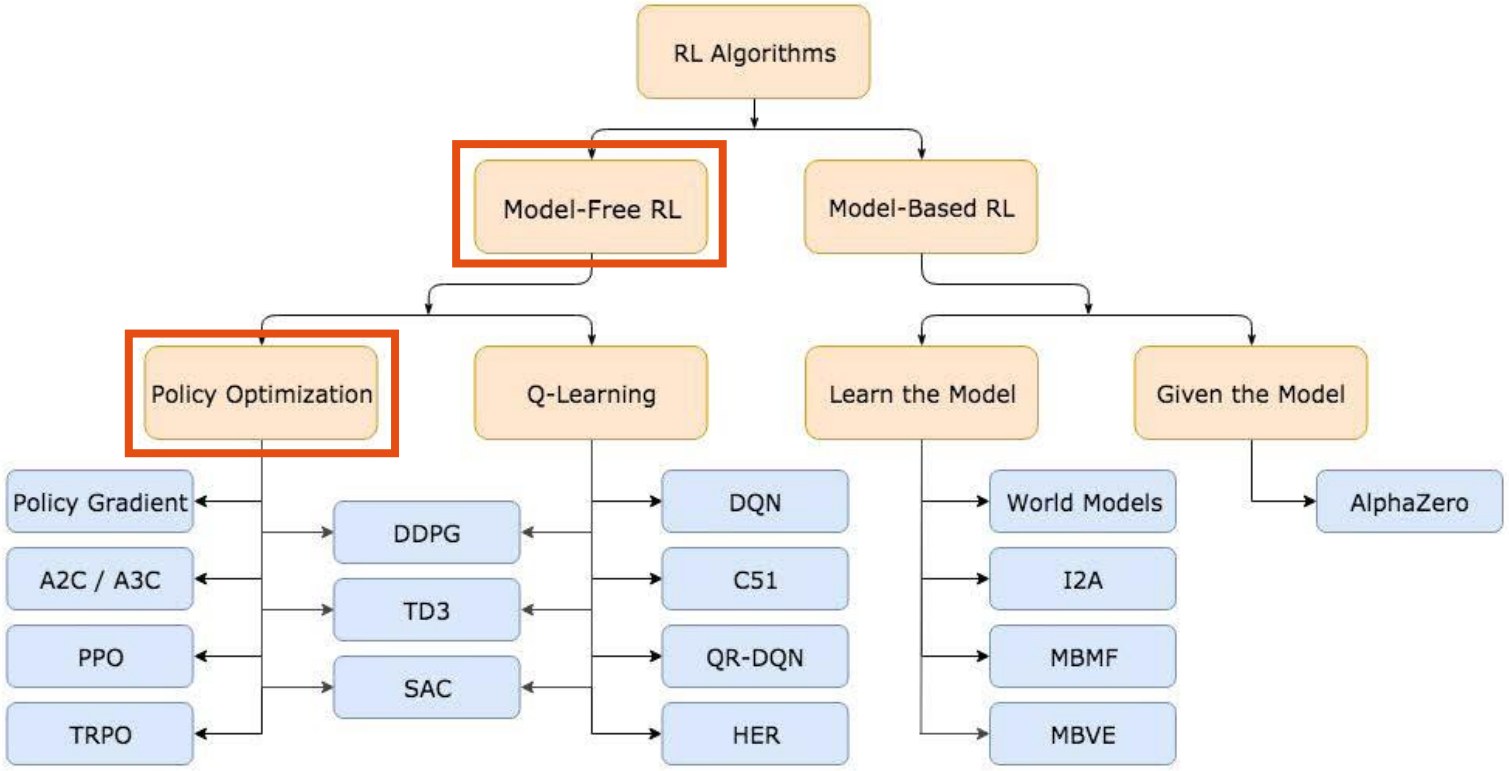

Motivación

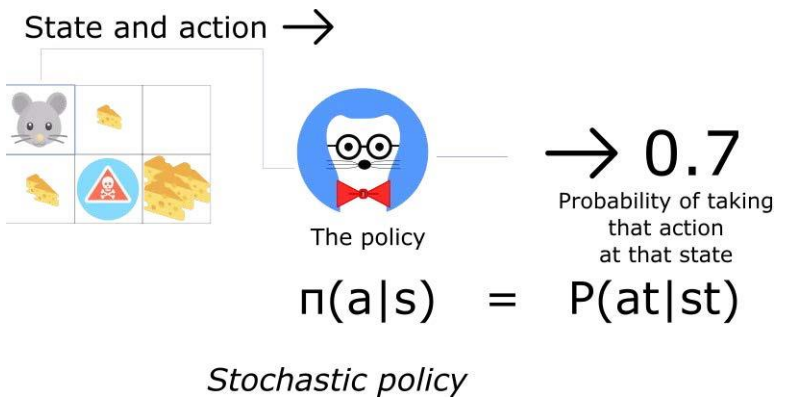

https://cdn-images-1.medium.com/max/1600/1*YCABimP7x1wZZZKqz2CoyQ.png

- **Policy,** π**.** Estrategia que sigue nuestro agente. Probabilidad de realizar una acción en un estado.

$$p(a|s) = \pi\,(s)\colon \pi\,(s)\ \in [0,1]$$

- **Q-learning.** Se sigue una **política voraz** respecto a la función Q, la cual debe estimarse previamente.

$$\pi\,(s) = argmax_a\left(q^{\pi}(s,a)\right)$$

- **Policy gradient (PG).** Tiene como objetivo **modelar directamente una distribución de probabilidad policy**, $\pi\,(s)$.

Motivación

PG vs. Q-learning

- PG permite obtener directamente **policies estocásticas** - e.g., $\pi(s) = [0, 0.2, 0.6, 0.2]$ -, mientras que Q-learning ofrece unicamente policies deterministas - e.g., $\pi(s) = [0, 0, 1, 0]$.

- PG permite modelar un espacio con **acciones continuas**. Funciona especialmente bien en espacios de acciones muy grandes.

- Q-learning busca obtener la major estimación de la función Q, para mejora de forma indirecta la policy**. PG actúa directamente sobre la policy**, lo cual mejora la **eficiencia y convergencia**.

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Deep Policy Gradient (DPG)

- Asunciones en **DQN: mejorando la estimación de la** q**,** ***indirectamente*** **mejoraremos la policy. Muchas ocasiones (espacio de acciones muy grande) dicha convergencia no sucede.**
- DPG: optimizamos la *policy* – distribución de probabilidad de acciones - directamente, $\pi\ (s)$.
- Uso de una **DNN,** $f_\theta(\cdot)$, como función **aproximadora** de $\pi^*(s)$.

$$\pi^*(s) = \left(f_\theta(s)\right)$$

- Debido a que la mayoría de simulaciones trabajan con la pantalla directamente, el tipo de red neuronal que usaremos serán **redes convolucionales**.

Conceptos importantes

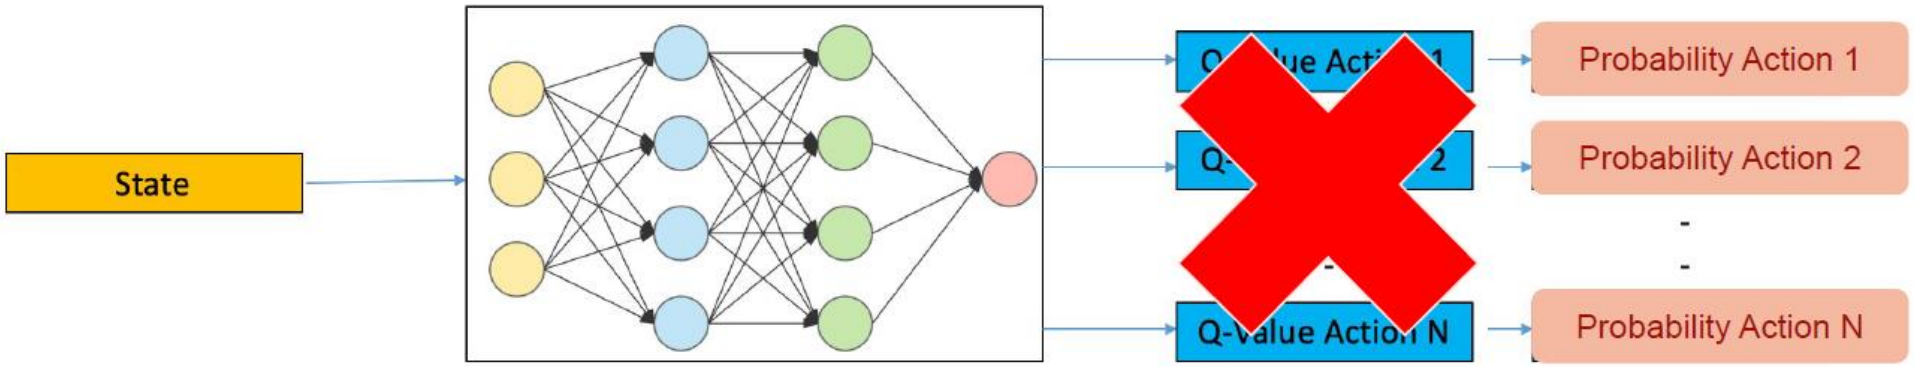

Deep Policy Gradient

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Trayectorias entorno-agente en PG

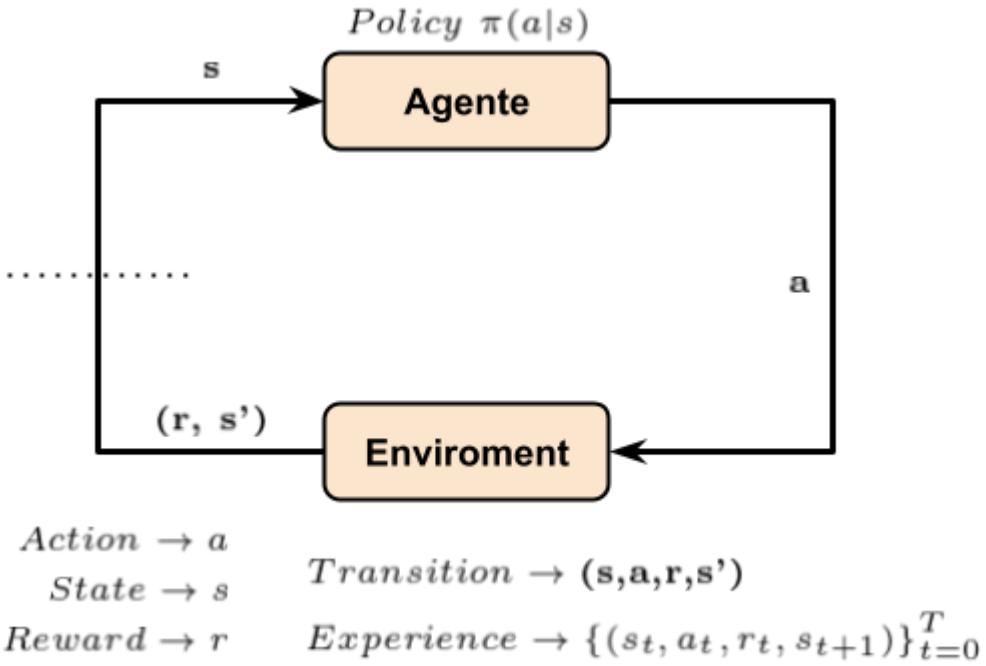

- En **PG**, trabajamos **on-policy**. Es decir, la memoria únicamente contiene **transiciones de una policy dada**. En este caso, se le llama **Trayectoria (T)**.

- Se define una **policy, $\boldsymbol{\pi(a|s)}$**, parametrizada por una DNN, que toma como entrada el estado pre-procesado, y devuelve una **distribución de probabilidad sobre las acciones, con activación softmax**. Por ejemplo $\pi\ (a|s^*) = [0.2,0.2,0.6,0]$.

$$\pi(a|s) = f_\theta(s)$$

- Seleccionamos la acción **a a partir de un muestreo de $\boldsymbol{\pi(a|s)}$**, lo cual permite la **exploración**.

$$a = sample\left(\pi\ (s)\right)$$

Aprendizaje supervisado

Una función de optimización típica de otra rama de *deep learning*, el **aprendizaje supervisado**, es la **entropía cruzada**, utilizando las probabilidades predichas, y un *one-hot-encoding* de la distribución de probabiliad predicha para el conjunto de etiquetas futuras.

$$L = -\sum y_i \, log \, (\hat{y}_i)$$

En **reinforcement learning, no existe un ground truth para una acción dada**, pero nos sirve para establecer ciertas **analogías**.

$$L = -\sum y_a \, log \, (\pi(s)_a)$$

Policy gradients – Naive solution

Se define un entorno con una **policy,** $\boldsymbol{\pi_\theta(\mathbf{a}|\mathbf{s})}$, que produce una distribución de probabilidad sobre el conjunto de acciones en una interacción agente-entorno. Esta interacción se realiza durante una trayectoria, de duración T, y en cada iteración, t_i, se produce una transición $(s_{t_i}, a_{t_i}, r_{t_i}, s_{t_i+1})$.

Se quiere optimizar la policy para acercarla en la mayor medida a una solución óptima. Policy Gradients (PG) se centra en actualizar $\boldsymbol{\pi_\theta}$ en dirección del gradiente de la misma. En el caso ideal, **si la acción seleccionada es la óptima, se quiere que su probabilidad sea lo más cercana a 1**, lo cual se conseguiría por descenso de gradiente.

$$\theta_{t_i+1} = \theta_{t_i} + \alpha \nabla \boldsymbol{\pi}_{\theta_{t_i}}\left(a^*_{t_i}|s_{t_i}\right) \quad (i)$$

Sin embargo, **la acción óptima no es conocida a priori**. Inicializando en una **policy aleatoria**, si optimizamos sobre una acción genérica (ii), estamos **optimizando soluciones sub-optimas**.

$$\theta_{t_i+1} = \theta_{t_i} + \alpha \nabla \boldsymbol{\pi}_{\theta_{t_i}}\left(a_{t_i}|s_{t_i}\right) \quad (ii)$$

Policy gradients – Ponderando acciones

Una solución para **ponderar los gradientes** es dar más importancia a aquellas acciones que den una mejor policy, es utilizar la información que proporciona el entorno como *feedback*: las **recompensas esperadas a futuro** dada la trayectoria realizada. Para ello, retomamos el concepto de función **quality** $\boldsymbol{q_\pi(s,a)}$:

$$q_\pi(s,a) = E_\pi[G_t|(s,a)]$$

Por lo tanto, la actualización de la policy en un step dado quedaría:

$$\theta_{t_i+1} = \theta_{t_i} + \alpha\, q_\pi(s_{t_i}, a_{t_i}) \nabla\, \boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i}) \quad (iii)$$

On-policy correction: actualizamos la policy en base a las acciones que toma la propia policy en una trayectoria. **Se debe compensar que acciones más probables serán llevadas a cabo más a menudo**. Por ello, se obtiene el *ratio* entre la actualización de la policy y la probabilidad de la acción tomada.

$$\theta_{t_i+1} = \theta_{t_i} + \alpha\, \frac{q_\pi(s_{t_i}, a_{t_i}) \nabla\, \boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i})}{\boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i})} \quad (iv)$$

¿Qué hay del logaritmo?

Aprendizaje supervisado: $L = -\sum y_i \, log \, (\hat{y}_i)$

RL, *Policy Gradient*: Podemos realizar el *log-derivative trick*, para obtener una expresión logarítmica de la actualización de los pesos.

$$\nabla \ln f(x) = \frac{\nabla f(x)}{f(x)} \rightarrow \frac{q_\pi(s_{t_i}, a_{t_i}) \nabla \, \boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i})}{\boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i})} = q_\pi(s_{t_i}, a_{t_i}) \nabla_{\theta_{t_i}} log \, \boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i})$$

Por tanto, el criterio de optimización de ***vanilla policy gradient*** consiste en:

$$\theta_{t_i+1} = \theta_{t_i} + \alpha \, q_\pi(s_{t_i}, a_{t_i}) \nabla_{\theta_{t_i}} log \, \boldsymbol{\pi}_{\theta_{t_i}}(a_{t_i}|s_{t_i}) \quad (v)$$

Suavizando recompensas

$$q_\pi(s,a) = [1.0, 1.1, 1.0, 1.0]$$
$$q_\pi(s,a) = [1.0, 0.0, 0.0, 0.0]$$

¿A qué acción se le debe dar mayor importancia al actualizar?

- Para **suavizar el problema con el uso de la recompensa como factor**, se proponen reemplazos de la función de calidad.

Policy gradient methods maximize the expected total reward by repeatedly estimating the gradient $g := \nabla_\theta \mathbb{E}\left[\sum_{t=0}^{\infty} r_t\right]$. There are several different related expressions for the policy gradient, which have the form

$$g = \mathbb{E}\left[\sum_{t=0}^{\infty} \Psi_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)\right], \tag{1}$$

where Ψ_t may be one of the following:

1. $\sum_{t=0}^{\infty} r_t$: total reward of the trajectory.
2. $\sum_{t'=t}^{\infty} r_{t'}$: reward following action a_t.
3. $\sum_{t'=t}^{\infty} r_{t'} - b(s_t)$: baselined version of previous formula.
4. $Q^\pi(s_t, a_t)$: state-action value function.
5. $A^\pi(s_t, a_t)$: advantage function.
6. $r_t + V^\pi(s_{t+1}) - V^\pi(s_t)$: TD residual.

The latter formulas use the definitions

$$V^\pi(s_t) := \mathbb{E}_{\substack{s_{t+1:\infty},\\ a_{t:\infty}}}\left[\sum_{l=0}^{\infty} r_{t+l}\right] \qquad Q^\pi(s_t, a_t) := \mathbb{E}_{\substack{s_{t+1:\infty},\\ a_{t+1:\infty}}}\left[\sum_{l=0}^{\infty} r_{t+l}\right] \tag{2}$$

$$A^\pi(s_t, a_t) := Q^\pi(s_t, a_t) - V^\pi(s_t), \quad \text{(Advantage function)}. \tag{3}$$

Estrategias de entrenamiento

Durante el proceso de aprendizaje debemos tener algunos conceptos y situaciones presentes, para entender qué está ocurriendo:

- Una de las primeras decisiones que debemos tomar es "**¿Cuántos *steps* vamos a usar para ir modificando la estrategia?**". El proceso de aprendizaje se puede ver más o menos impactado dependiendo del número de iteraciones que realicemos para ir almacenando nuestra experiencia.

- Además, al trabajar con la trayectoria, **las recompensas obtenidas se procesarán siguiendo un enfoque conocido como *discounted rewards***. Al tener una trayectoria finita, utilizaremos las recompensas en sentido inverso para ir estimando la recompensa esperada a futuro (G) en los siguientes estados y de esta forma poder ponderar las acciones de manera adecuada.

- Por otro lado, **usar la recompensa como factor de las probabilidades de las acciones produce una varianza en los datos muy grande**. Tened en cuenta que con esta definición la probabilidad de una acción en un estado puede cambiar dependiendo de si la recompensa cambia también. Esto **dificulta el aprendizaje** ya que **no se encuentra una correlación entre estado y probabilidad de acción fácilmente**. Esta situación se puede dar en muchos escenarios, sobre todo en las simulaciones basadas en videojuegos.

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

REINFORCE

function REINFORCE

Initialise θ arbitrarily

for each episode $\{s_1, a_1, r_2, ..., s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$ **do**

for $t = 1$ to $T - 1$ **do**

$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) v_t$

end for

end for

return θ

end function

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Vanilla Policy Gradient

Algorithm 1 "Vanilla" policy gradient algorithm

Initialize policy parameter θ, baseline b

for iteration=1, 2, . . . **do**

Collect a set of trajectories by executing the current policy

At each timestep in each trajectory, compute

the *return* $R_t = \sum_{t'=t}^{T-1} \gamma^{t'-t} r_{t'}$, and

the *advantage estimate* $\hat{A}_t = R_t - b(s_t)$.

Re-fit the baseline, by minimizing $\|b(s_t) - R_t\|^2$,

summed over all trajectories and timesteps.

Update the policy, using a policy gradient estimate $\hat{g}$,

which is a sum of terms $\nabla_\theta \log \pi(a_t \mid s_t, \theta)\hat{A}_t$

end for

Baseline, reducir la varianza!

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Conclusiones

- **Policy Gradient** es uno de los algoritmos base dentro del aprendizaje por refuerzo. Este algoritmo es el **origen de algunos de los algoritmos más potentes actualmente**. Es un algoritmo de tipo **on-policy**.

- En comparación con DQN, algunas de las características a destacar son una mayor capacidad de **convergencia**, apto para trabajar con **espacios de acciones grandes (y continuos)** y posibilidad de aprender **policies estocásticas**.

- La **función de coste** en Policy Gradient se centra en ir optimizando la propia policy aplicando ***gradient ascent* sobre la probabilidad de la acción seleccionada y su recompensa obtenida**.

- Al ser un algoritmo base, veremos en las siguientes sesiones de la asignatura las evoluciones que se han ido produciendo para estabilizar y mejorar el proceso de aprendizaje del agente.

Índice

Definición Policy Gradient

Deep Policy Gradient

Proceso de aprendizaje

Algoritmo: REINFORCE

Algoritmo: Vanilla Policy Gradient

Conclusiones

Bibliografía recomendada

Bibliografía recomendada

- “Reinforcement Learning: An Introduction”, Sutton y Barto:
http://incompleteideas.net/book/bookdraft2017nov5.pdf
(Capítulo 13, Policy Gradient Methods)

- An Intuitive explanation on Policy Gradients, Adrien Lucas, Towards data science / Medium
https://towardsdatascience.com/an-intuitive-explanation-of-policy-gradient-part-1-reinforce-aa4392cbfd3c

Universidad
Internacional
de Valencia

universidadviu.com

De:
Planeta Formación y Universidades